Flow 기반 NIDS 실험 결과 정리 (TCN / OCSVM)

1. 각 모델 출력 점수 분포 및 Threshold 분석

1-1. TCN

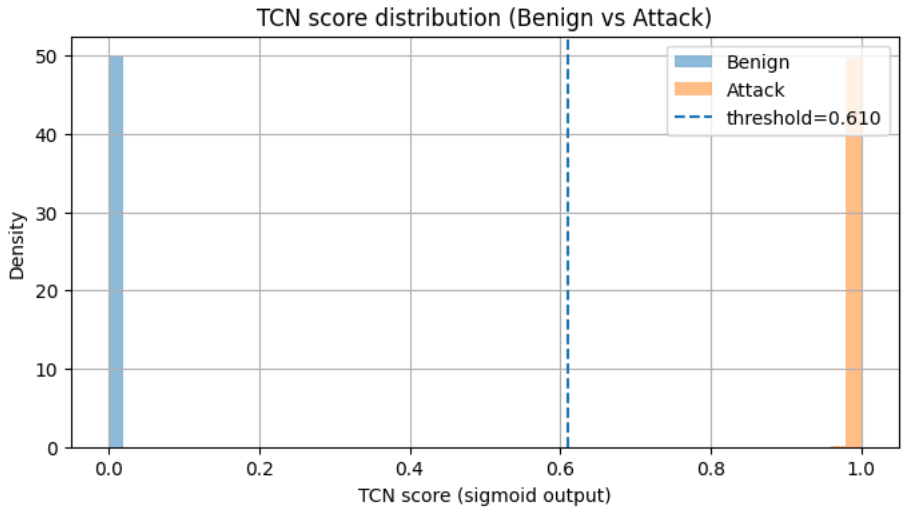

TCN의 출력 score는 sigmoid 함수 결과로, 값이 클수록 공격(Attack)일 가능성이 높고, 값이 작을수록 정상(Benign)일 가능성이 높은 연속값이다.

TCN score 분포 그래프에서 Benign 트래픽은 0에 가까운 낮은 score 영역에 밀집되어 있으며, Attack 트래픽은 1에 가까운 높은 score 영역에 집중되는 양상이 관찰된다. 이는 TCN이 정상과 공격을 score 공간에서 비교적 명확하게 분리하고 있음을 의미한다.

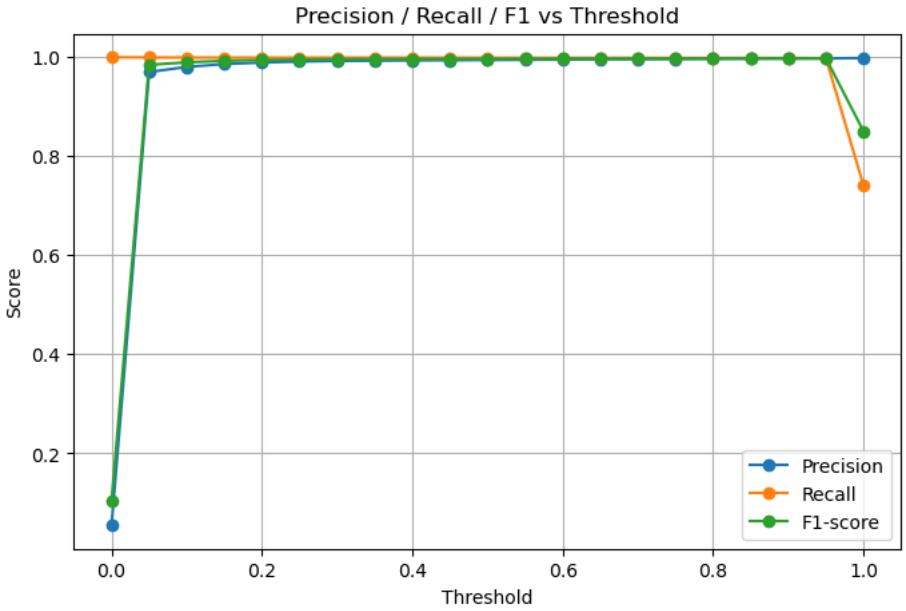

Threshold 변화에 따른 Precision, Recall, F1-score 그래프는 임계값 선택에 따른 성능 변

화를 보여준다.

낮은 threshold에서는 공격을 과도하게 탐지하여 Precision이 낮아지고, 높은 threshold에서는 일부 공격을 놓쳐 Recall이 감소하는 경향이 나타난다. 중간 구간에서는 Precision과 Recall이 모두 안정적으로 유지되는 영역이 형성된다.

모델을 선정할 때, 단순히 F1-score 최대값만을 기준으로 threshold를 선택하지 않고, Attack 클래스에 대해 Precision ≥ 0.995, Attack Recall ≥ 0.995 조건을 만족하는 threshold 후보들 중에서 가장 높은 F1-score를 보이는 지점을 최종 threshold로 선택하였다.

1-2. OCSVM

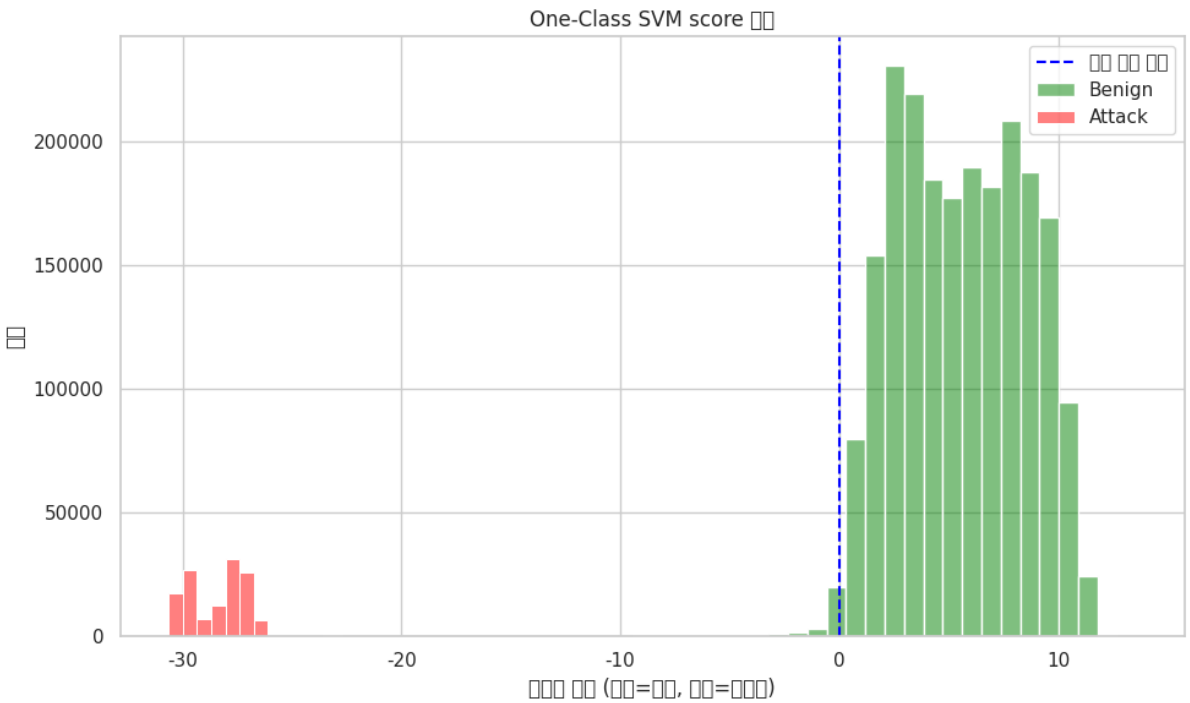

OCSVM의 anomaly score는 값이 클수록 정상(Benign)에 가깝고, 값이 작을수록 정상 분포에서 벗어난 이상(Attack)에 가까움을 의미한다. 즉, TCN과는 score 해석 방향이 반대이다.

그래프에서 Benign 트래픽은 높은 score 영역에 밀집되어 있으며, Attack 트래픽은 낮은 score 영역으로 분포하는 경향이 나타난다. 이는 OCSVM이 정상 데이터 분포를 기준으로 경계를 형성하고, 그 경계에서 벗어난 샘플을 이상으로 판단하고 있음을 보여준다.

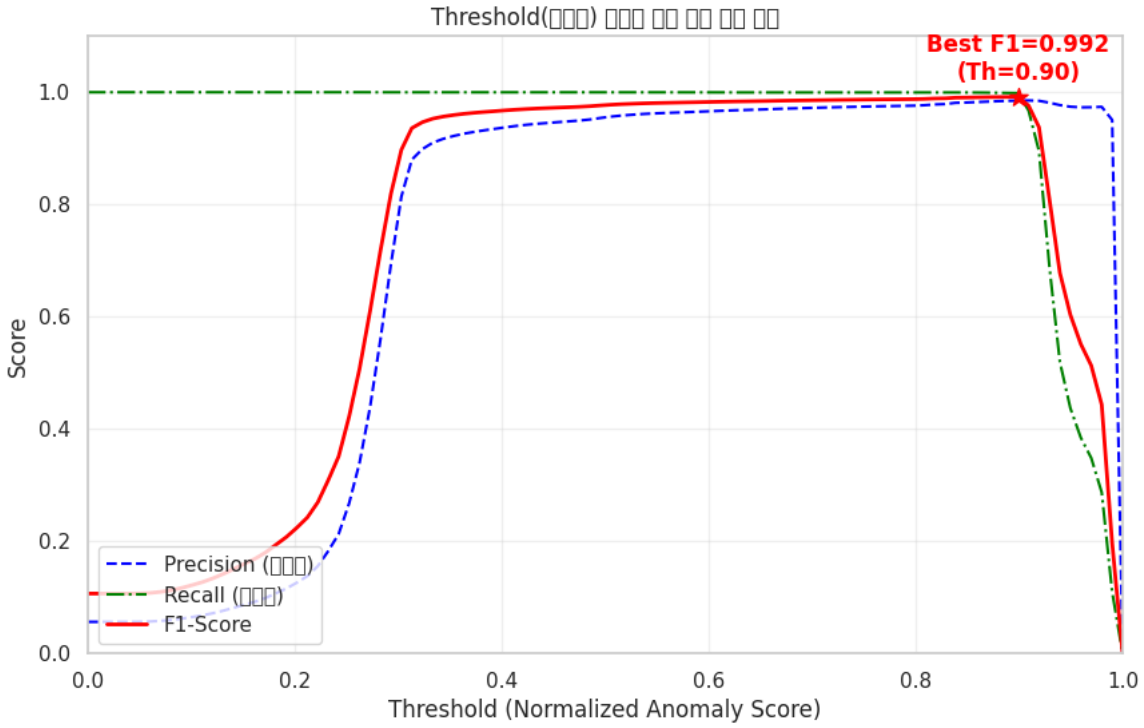

OCSVM에서는 TCN과 동일한 기준(Precision ≥ 0.995, Recall ≥ 0.995)을 적용할 경우 이를 동시에 만족하는 threshold가 존재하지 않았다.

따라서 OCSVM의 threshold는 F1-score가 상대적으로 높은 구간 중에서 Precision과 Recall이 가장 균형에 가까운 지점을 기준으로 설정하였다. 즉, 완전한 정량 조건 충족이 아닌, 가장 합리적인 trade-off 지점을 선택하는 방식으로 threshold를 결정하였다.

2. Bengin vs Attack 주요 feature 분포 비교

본 분석에서는 모든 입력 feature를 시각화하지 않고, TCN의 SHAP 분석 결과에서 중요도가 높게 나타난 feature들을 중심으로 Benign과 Attack 분포를 비교하였다.

2-1. TCN

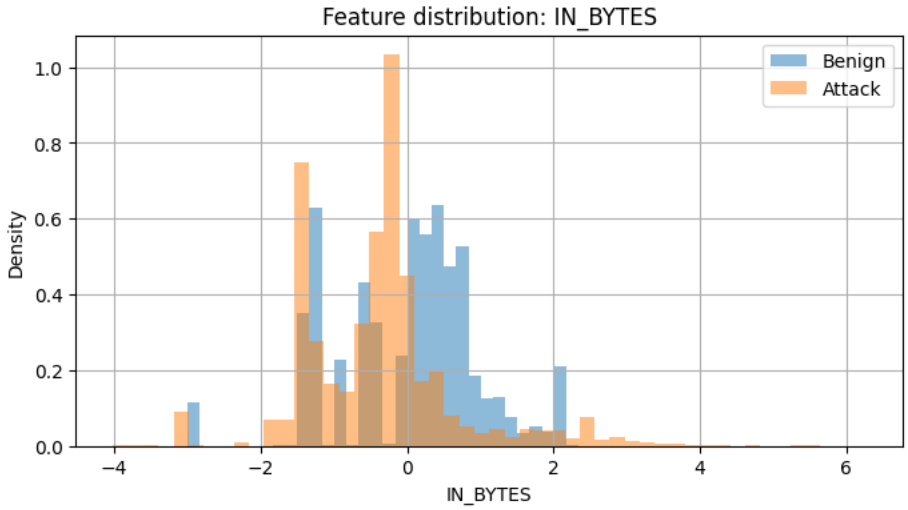

IN_BYTES 분포를 비교한 결과, 공격 트래픽은 정상 대비 더 작거나 특정 값에 집중되는 경향을 보인다.

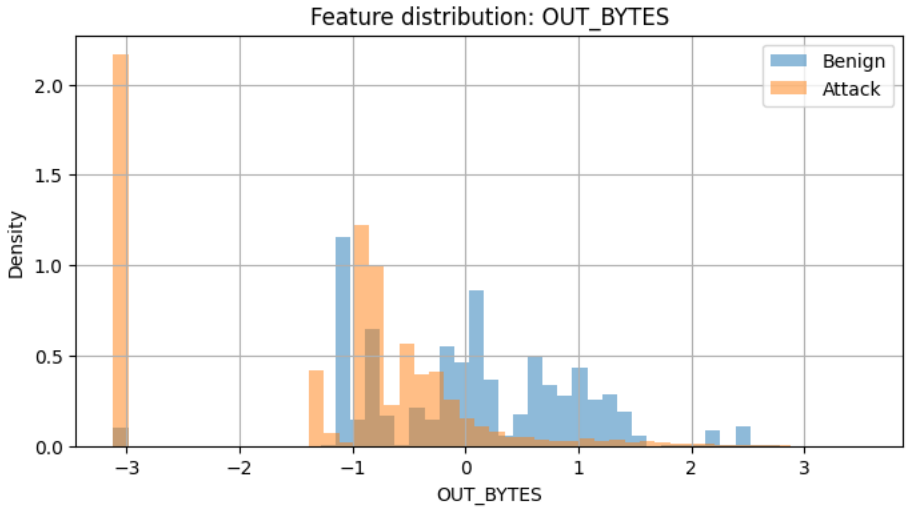

OUT_BYTES 분포를 비교한 결과, 공격 트래픽은 정상 대비 더 넓은 분산과 극단값을 포함하는 경향을 보인다.

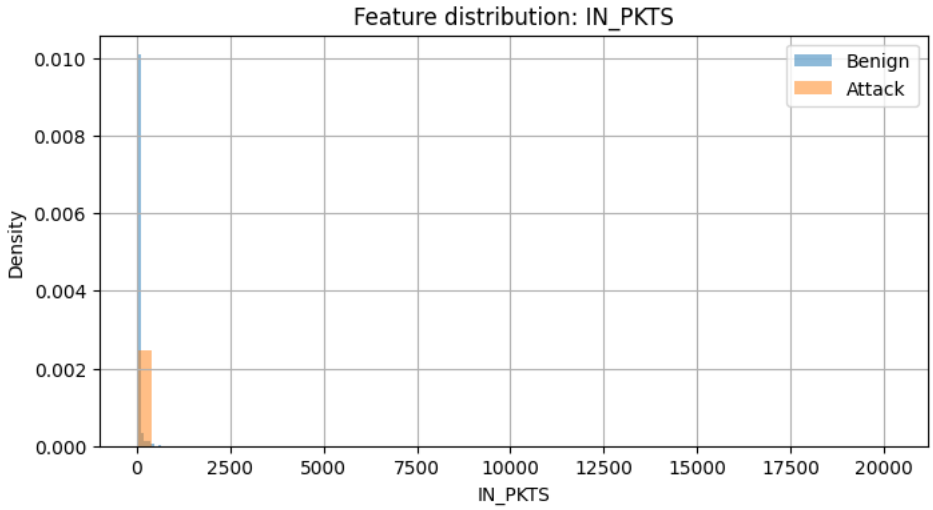

IN_PKTS 분포에서는 공격 트래픽이 정상 대비 특정 구간에 집중되거나, 비정상적으로 높은 패킷 수를 보이는 경우가 관찰된다.

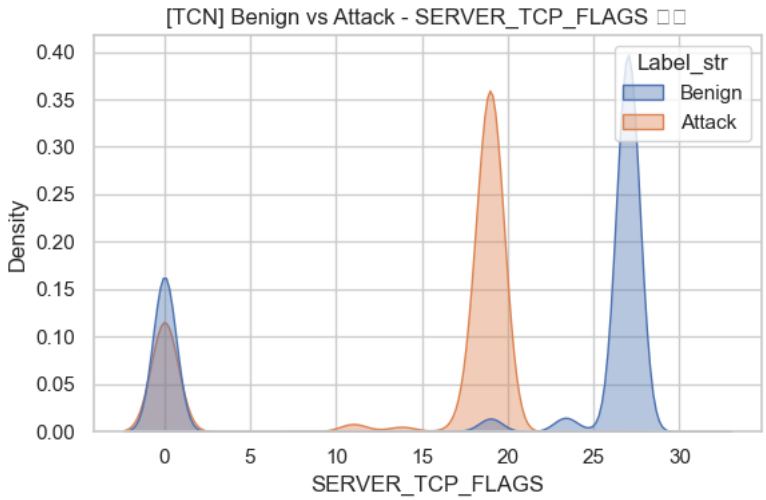

SERVER_TCP_FLAGS는 TCP 세션의 상태 조합을 수치화한 feature로, 정상 통신과 비정상 통신 간의 연결 상태 차이를 반영한다.

Attack 트래픽은 특정 TCP 상태 값에 집중되어 있는 반면, Benign 트래픽은 다른 구간 또는 다봉 분포를 보인다.

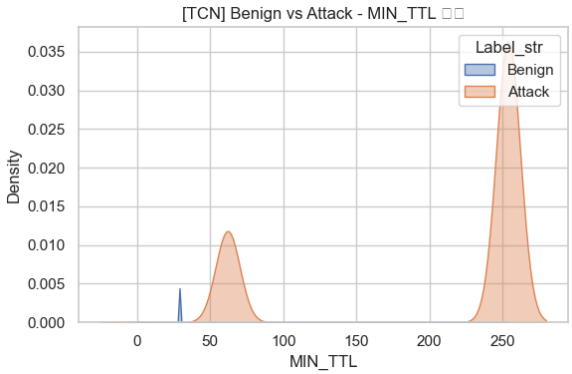

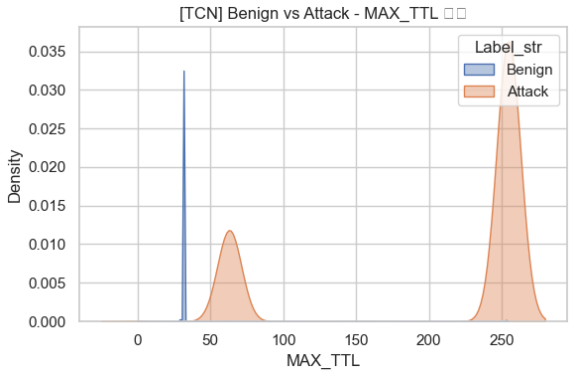

TTL(Time To Live)은 패킷이 네트워크를 통과할 수 있는 홉 수를 의미하며, 발신 환경(OS, 공격 도구, 네트워크 경로 특성)의 영향을 받는다.

Benign 트래픽은 비교적 일정한 TTL 범위에 집중되어 있는 반면, Attack 트래픽은 극단적으로 높은 값(예: 255 근처)이나 이중 분포 형태를 보인다.

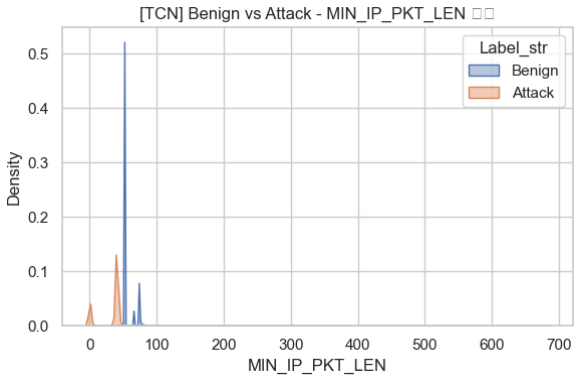

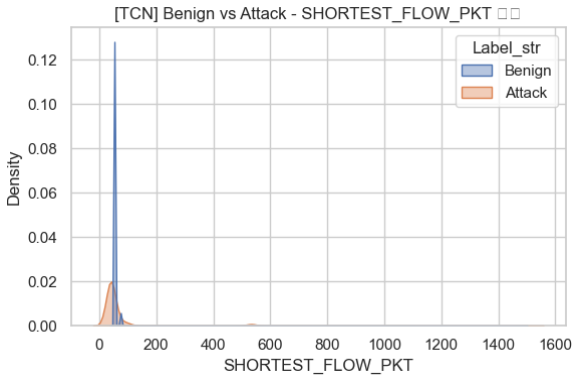

해당 feature들은 세션 내에서 가장 작은 패킷 또는 가장 짧은 패킷 흐름을 나타내며, 트래픽의 최소 단위 특성을 반영한다.

Attack 트래픽은 정상 대비 매우 작은 패킷 길이를 포함하는 경우가 많으며, 이는 스캔, probing, 실패한 연결 시도 등 공격 트래픽의 특성과 일치한다. 정상 트래픽은 상대적으로 안정적인 최소 패킷 길이를 유지한다.

2-2. OCSVM

OCSVM은 정상(Benign) 데이터만을 학습하여 정상 분포의 경계를 형성하고, 해당 분포에서 벗어나는 flow를 이상(Attack)으로 판단하는 모델이다. 따라서 OCSVM의 feature 분포 비교는 "공격의 의미"를 설명하기보다는, 정상 트래픽이 가지는 안정적인 분포가 어떻게 깨지는지를 확인하는 관점에서 해석한다.

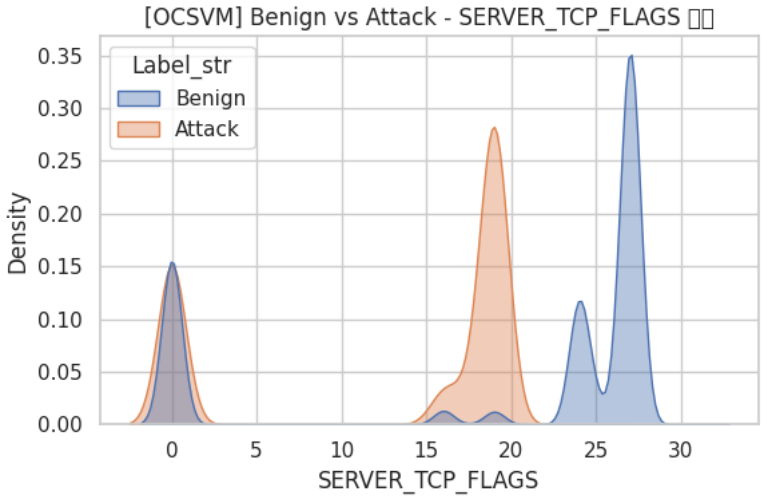

SERVER_TCP_FLAGS는 서버 관점에서 관찰된 TCP 플래그 조합을 수치화한 feature로, 연결 상태와 세션 흐름을 반영한다.

Benign 트래픽은 다양한 정상 통신 상태가 공존하여 다봉 분포를 형성하는 반면, Attack 트래픽은 특정 TCP 상태 값에 상대적으로 집중되는 경향을 보인다.

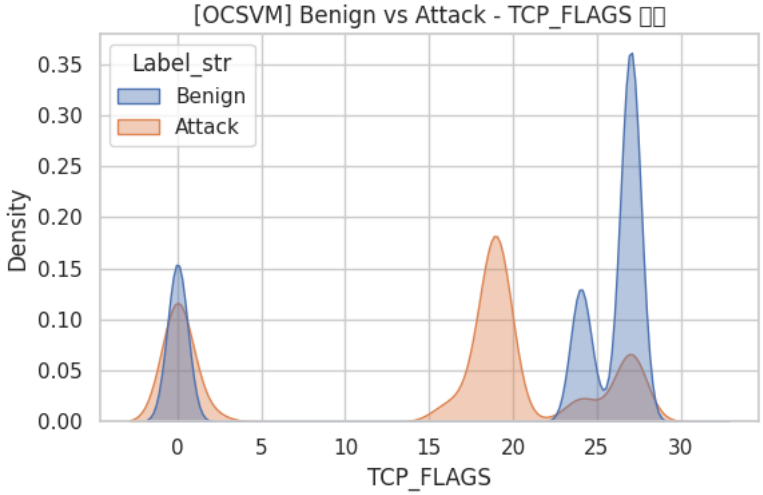

TCP_FLAGS는 전체 TCP 세션에서 관찰된 플래그 조합을 반영하는 feature로, 통신 흐름의 정상성 여부를 나타낸다.

Attack 트래픽 중 일부는 정상 분포 외부에 위치한 봉을 형성하였으나, 상당수의 Attack 트래픽은 Benign 분포 내부에 중첩되어 나타났다. 이는 TCP 플래그 정보만으로는 정상 통신과 공격 통신을 완전히 분리하기 어렵다는 점을 의미한다.

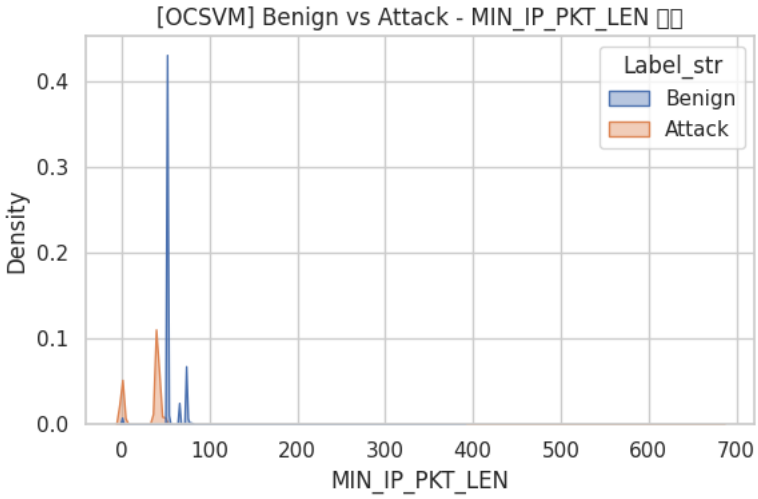

MIN_IP_PKT_LEN은 flow 내에서 가장 작은 IP 패킷 길이를 의미하며, 통신의 최소 단위 특성을 반영한다.

Attack 트래픽은 정상 대비 매우 작은 패킷 길이를 포함하는 경우가 많으며, 이는 스캔, probing, 혹은 실패한 연결 시도에서 발생하는 짧은 패킷들이 반영된 결과이다. Benign 트래픽은 상대적으로 안정적인 최소 패킷 길이를 유지한다.

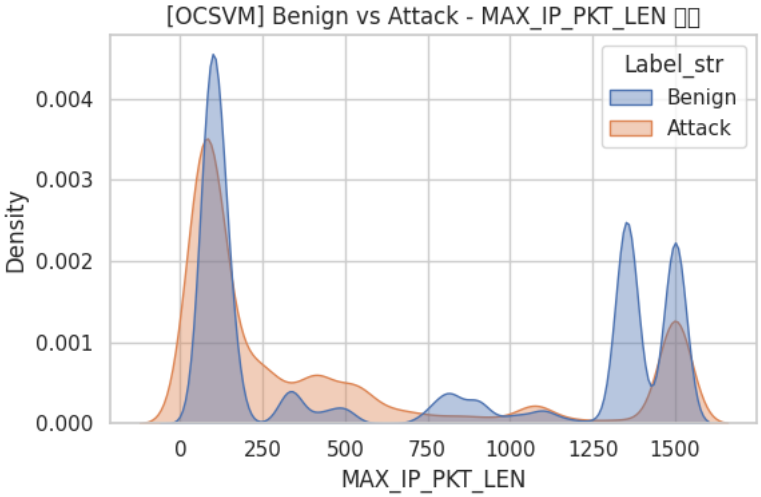

MAX_IP_PKT_LEN은 flow 내 IP 패킷 중 최대 길이를 의미하며, 통신에서 사용되는 최대 페이로드 크기 특성을 반영한다.

Benign 트래픽은 비교적 일관된 최대 패킷 길이 분포를 유지하는 반면, Attack 트래픽은 정상 분포 범위를 벗어나는 값들이 더 자주 관찰된다. 이는 공격 트래픽이 비정상적인 패킷 크기를 사용하거나, 프로토콜 규격을 벗어난 패킷을 포함하는 경우가 많기 때문이다.

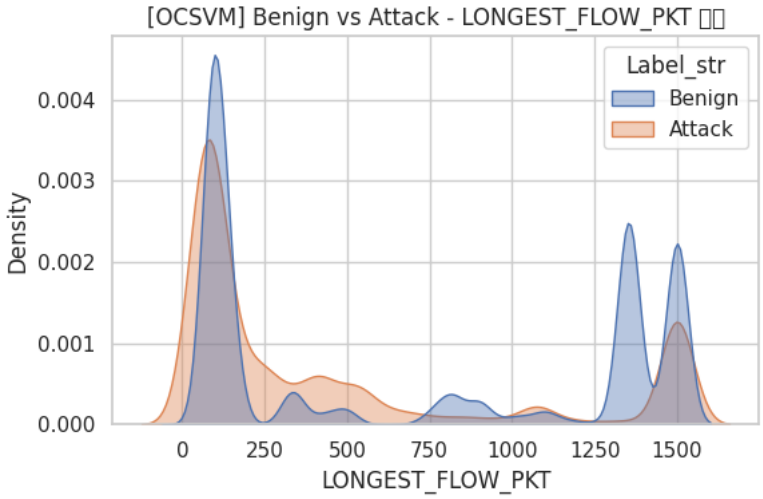

LONGEST_FLOW_PKT는 하나의 flow 내에서 가장 긴 패킷의 크기를 나타내며, 세션 중 최대 전송 단위 특성을 반영한다.

Benign 트래픽은 특정 구간에 비교적 안정적으로 분포하며, 서비스 특성에 따라 일부 큰 패킷 구간에서도 봉우리가 형성된다. 반면 Attack 트래픽은 분포가 더 넓게 퍼지거나, 정상 분포 외 영역으로 확장되는 경향을 보인다. 이는 공격 트래픽이 비정상적으로 큰 패킷을 포함하거나, 정상적인 세션 구조를 따르지 않는 경우가 많기 때문으로 해석할 수 있다.

3. 공격 유형별 점수 분포 분석

3-1. TCN

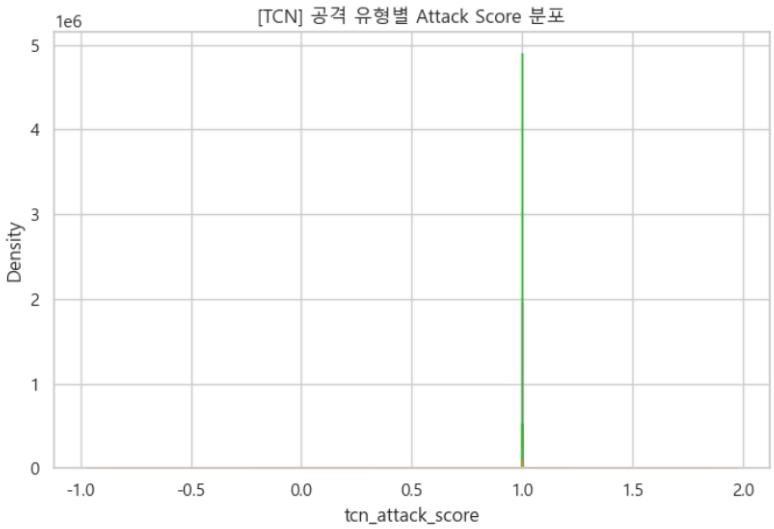

	Attack	tcn_score	IN_BYTES	OUT_BYTES	IN_PKTS	MAX_TTL	MIN_TTL
0	Analysis	1.000000	-0.064278	-0.467854	12.000000	255.0	254.0
1	Analysis+DoS	1.000000	-0.227189	-0.877332	10.000000	255.0	254.0
2	Analysis+Exploits	1.000000	0.090254	-0.021147	10.000000	255.0	254.0
3	Analysis+Exploits+Reconnaissance	1.000000	-0.478222	-3.116464	2.000000	254.0	254.0
4	Analysis+Fuzzers	1.000000	0.451052	-0.877332	10.000000	255.0	254.0
5	Analysis+Fuzzers+DoS	0.999798	-0.246690	-0.222907	10.000000	63.0	62.0
6	Analysis+Fuzzers+Reconnaissance	0.999717	-0.255900	-0.287338	10.000000	63.0	62.0
7	Analysis+Generic	0.999994	3.615827	0.173065	312.000000	63.0	62.0
8	Analysis+Reconnaissance	1.000000	-0.493860	-0.767977	10.000000	255.0	254.0
9	Analysis+Reconnaissance+Exploits	1.000000	-1.636447	-3.116464	2.000000	254.0	254.0
10	Backdoor	1.000000	-0.307449	-0.877332	10.000000	255.0	254.0
11	Backdoor+DoS	1.000000	-0.134049	-0.414613	12.000000	255.0	254.0
12	Backdoor+DoS+Reconnaissance	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
13	Backdoor+Exploits	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
14	Backdoor+Fuzzers	1.000000	-0.083935	-3.116464	2.000000	254.0	254.0
15	Backdoor+Generic	1.000000	-0.568239	-3.116464	2.000000	254.0	254.0
16	Backdoor+Generic+Exploits	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
17	Backdoor+Reconnaissance	1.000000	0.043182	-0.877332	10.000000	255.0	254.0
18	Backdoor+Reconnaissance+Exploits	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
19	Backdoor+Shellcode	1.000000	-0.112780	-0.767977	10.000000	255.0	254.0
20	Backdoor+Shellcode+Exploits+Fuzzers	0.999991	-0.581109	-3.116464	8.000000	255.0	254.0
21	DoS	1.000000	-0.682713	-3.116464	2.000000	158.0	158.0
22	DoS+Analysis	1.000000	-1.533040	-3.116464	2.000000	254.0	254.0
23	DoS+Analysis+Reconnaissance	1.000000	2.515979	-0.550983	60.000000	255.0	254.0
24	DoS+Backdoor	1.000000	0.632302	-0.877332	10.000000	255.0	254.0
25	DoS+Exploits	1.000000	-0.814884	-3.116464	2.000000	254.0	254.0
26	DoS+Fuzzers	1.000000	-0.467287	-0.767977	10.000000	255.0	254.0
26	DoS+Fuzzers	1.000000	-0.467287	-0.767977	10.000000	255.0	254.0
27	DoS+Generic	1.000000	-1.235347	-3.116464	2.000000	254.0	254.0
28	DoS+Reconnaissance	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
29	DoS+Reconnaissance+Exploits	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
30	DoS+Reconnaissance+Fuzzers	1.000000	-0.131509	-1.343240	6.000000	63.0	62.0
31	DoS+Shellcode	1.000000	-1.533040	-3.116464	2.000000	254.0	254.0
32	Exploits	1.000000	1.571063	-0.767977	18.000000	255.0	254.0
33	Exploits+Analysis	1.000000	1.077427	-0.877332	14.000000	255.0	254.0
34	Exploits+Analysis+Generic	0.999627	-0.176159	-0.140189	10.000000	63.0	62.0
35	Exploits+Analysis+Reconnaissance	0.999971	2.984494	0.021649	128.000000	63.0	62.0
36	Exploits+Backdoor	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
37	Exploits+Backdoor+Reconnaissance	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
38	Exploits+DoS	1.000000	-0.236114	-0.877332	10.000000	255.0	254.0
39	Exploits+DoS+Reconnaissance	1.000000	-1.893584	-3.116464	2.000000	254.0	254.0
40	Exploits+DoS+Shellcode	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
41	Exploits+Fuzzers	1.000000	-1.893584	-3.116464	2.000000	254.0	254.0
42	Exploits+Fuzzers+Generic	1.000000	-1.235347	-3.116464	2.000000	254.0	254.0
43	Exploits+Generic	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
44	Exploits+Reconnaissance	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
45	Exploits+Reconnaissance+DoS	0.999526	0.053638	0.016541	12.000000	63.0	62.0
46	Exploits+Reconnaissance+Fuzzers	1.000000	-1.265680	-1.343240	4.000000	255.0	254.0
47	Exploits+Shellcode	1.000000	-0.134049	-0.767977	10.000000	255.0	254.0
48	Exploits+Shellcode+Reconnaissance	1.000000	-1.235347	-3.116464	2.000000	254.0	254.0
49	Exploits+Worms	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
50	Fuzzers	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
51	Fuzzers+Analysis	1.000000	-0.164026	-0.767977	10.000000	255.0	254.0
52	Fuzzers+Backdoor	1.000000	-0.083935	-3.116464	2.000000	254.0	254.0
53	Fuzzers+DoS	1.000000	-1.533040	-3.116464	2.000000	254.0	254.0

53	Fuzzers+DoS	1.000000	-1.533040	-3.116464	2.000000	254.0	254.0
54	Fuzzers+DoS+Exploits+Shellcode+Generic	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
55	Fuzzers+Exploits	1.000000	2.517523	-0.498590	60.000000	255.0	254.0
56	Fuzzers+Generic	1.000000	0.451052	-0.877332	10.000000	255.0	254.0
57	Fuzzers+Generic+Exploits	1.000000	-0.139160	-1.343240	6.000000	63.0	62.0
58	Fuzzers+Reconnaissance	1.000000	-0.528747	-0.767977	10.000000	255.0	254.0
59	Fuzzers+Shellcode	1.000000	-1.533040	-3.116464	2.000000	254.0	254.0
60	Fuzzers+Shellcode+Exploits	1.000000	-1.366648	-3.116464	2.000000	254.0	254.0
61	Generic	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
62	Generic+Analysis	1.000000	-0.493860	-0.767977	10.000000	255.0	254.0
63	Generic+Backdoor	1.000000	-1.636447	-3.116464	2.000000	254.0	254.0
64	Generic+DoS	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
65	Generic+Exploits	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
66	Generic+Fuzzers	1.000000	-1.893584	-3.116464	2.000000	254.0	254.0
67	Generic+Fuzzers+Exploits	1.000000	-1.687809	-0.998091	3.666667	255.0	254.0
68	Generic+Reconnaissance	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
69	Reconnaissance	1.000000	-1.192440	-3.116464	2.000000	254.0	254.0
70	Reconnaissance+Analysis	1.000000	-0.041938	-0.414277	12.000000	255.0	254.0
71	Reconnaissance+DoS	1.000000	-0.540823	-0.877332	10.000000	255.0	254.0
72	Reconnaissance+DoS+Exploits	1.000000	-0.376624	-0.767977	10.000000	255.0	254.0
73	Reconnaissance+Exploits	1.000000	1.876587	-3.116464	314.000000	255.0	254.0
74	Reconnaissance+Exploits+Analysis	0.999998	0.512367	2.113819	66.000000	63.0	62.0
75	Reconnaissance+Exploits+DoS	0.999187	-0.219848	-0.285885	10.000000	63.0	62.0
76	Reconnaissance+Exploits+Generic	1.000000	2.517578	-0.550983	60.000000	255.0	254.0
77	Reconnaissance+Fuzzers	1.000000	-1.533040	-3.116464	2.000000	254.0	254.0
78	Reconnaissance+Fuzzers+Exploits	1.000000	-0.205418	-0.767977	10.000000	255.0	254.0
79	Reconnaissance+Generic	1.000000	0.451052	-0.877332	10.000000	255.0	254.0
80	Reconnaissance+Shellcode	1.000000	-0.445973	-0.512333	10.000000	255.0	254.0

80	Reconnaissance+Shellcode	1.000000	-0.445973	-0.512333	10.000000	255.0	254.0
81	Reconnaissance+Shellcode+Generic	0.999149	0.055521	-0.481749	4.000000	255.0	254.0
82	Shellcode	1.000000	-0.083935	-3.116464	2.000000	254.0	254.0
83	Shellcode+Backdoor	1.000000	-0.340195	-0.877332	10.000000	255.0	254.0
84	Shellcode+Exploits	1.000000	-1.126884	-3.116464	2.000000	254.0	254.0
85	Shellcode+Fuzzers	1.000000	-0.528747	-0.767977	10.000000	255.0	254.0
86	Shellcode+Generic	1.000000	-1.102472	-3.116464	4.000000	255.0	254.0
87	Shellcode+Reconnaissance	1.000000	2.517614	-0.550983	60.000000	255.0	254.0
88	Worms	1.000000	-0.083935	-3.116464	2.000000	254.0	254.0

공격 유형별 TCN score 분포를 분석한 결과, 공격 유형에 따라 score의 집중 구간과 분포 형태가 상이하게 나타났다. 일부 공격 유형은 매우 높은 score 영역에 집중되어 나타난 반면, 다른 공격 유형은 상대적으로 넓은 score 분포를 보였다. 이는 TCN이 모든 공격을 동일한 기준으로 판단하는 것이 아니라, 공격 유형별로 서로 다른 시계열적 행위 특성을 학습하고 있음을 의미한다.

3-2. OCSVM

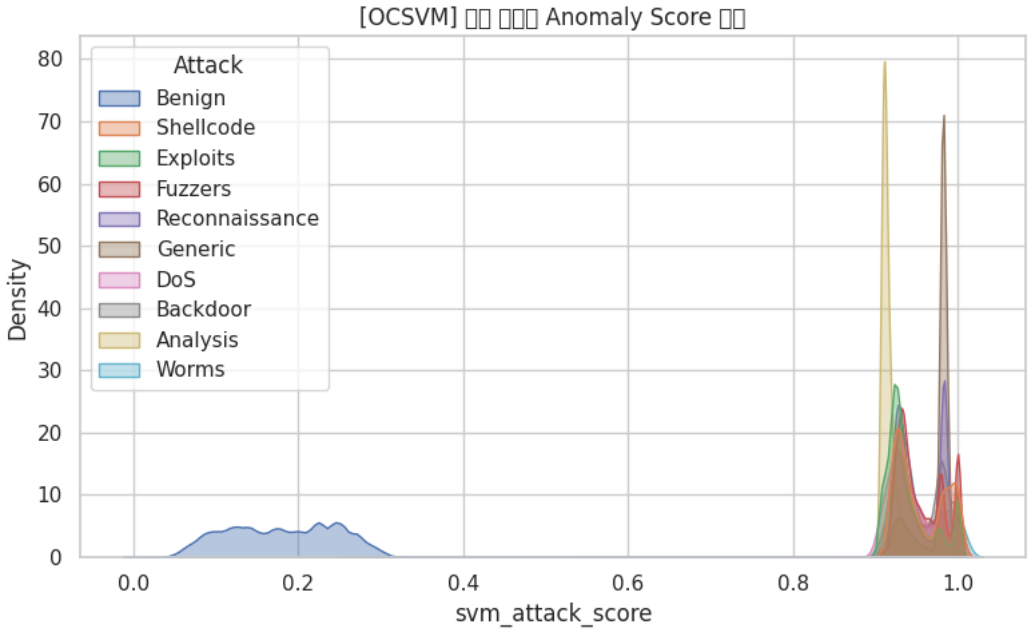

OCSVM의 anomaly score를 공격 유형별로 분석한 결과, 대부분의 공격 유형이 유사한 높은 anomaly 영역에 분포하는 경향을 보였다. 이는 OCSVM이 공격 유형 간의 세부적인 차이를 구분하기보다는, 정상 분포에서 벗어났는지 여부에 초점을 맞추어 공격을 하나의 이상 집합으로 묶어 판단하고 있음을 보여준다.

4. SHAP 기반 XAI 결과 해석

4-1. TCN

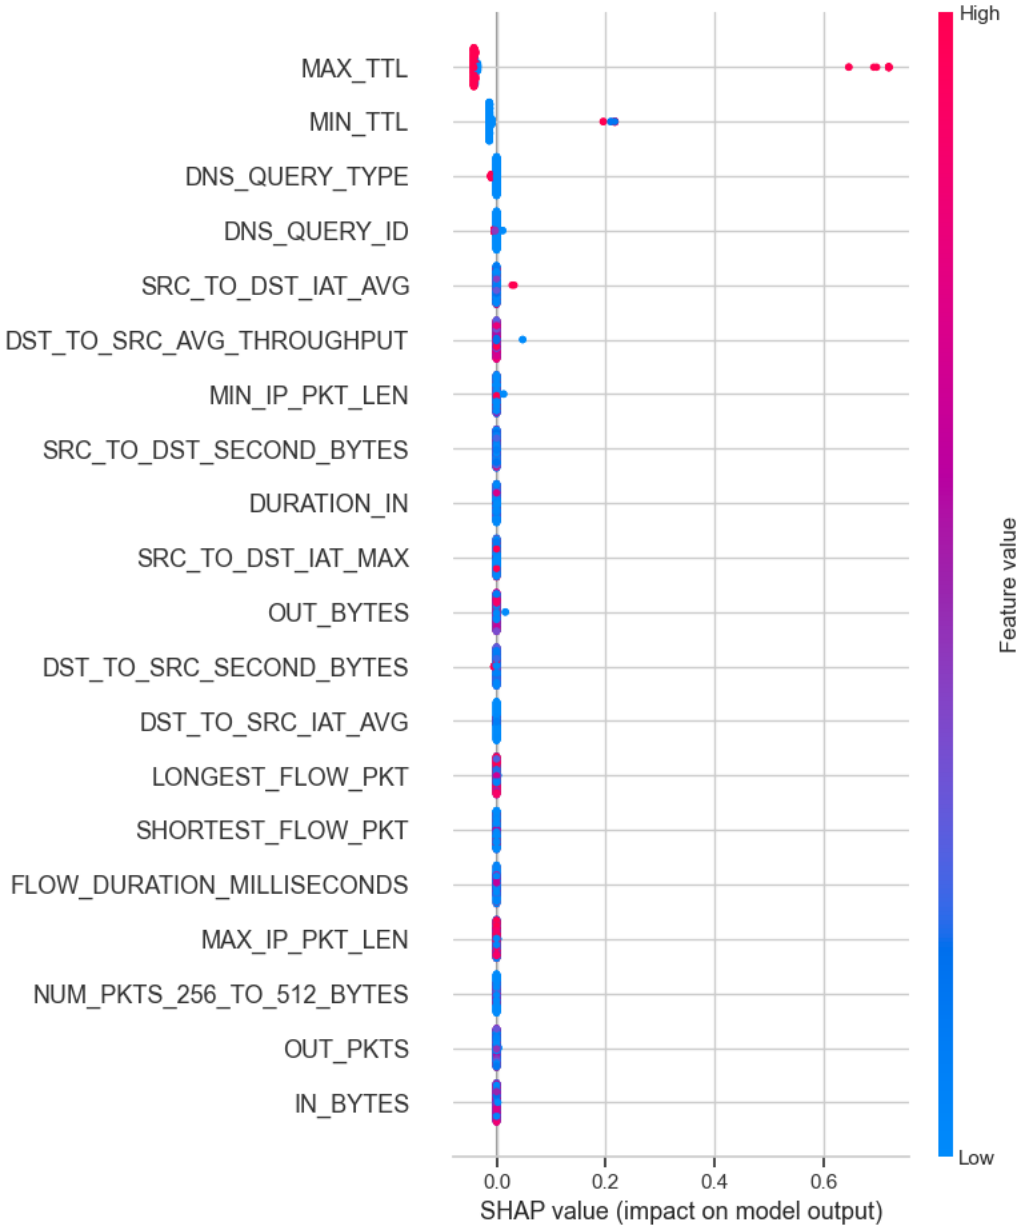

SHAP summary plot은 전체 데이터셋을 기준으로 각 feature가 TCN 모델 출력에 미치는 상대적 영향도를 나타낸다. x축의 SHAP 값은 해당 feature가 모델 출력(score)을 공격 방향(양의 방향) 또는 정상 방향(음의 방향)으로 얼마나 이동시키는지를 의미하며, 색상은 feature 값의 크기를 나타낸다.

SHAP force plot은 개별 flow에 대해 각 feature가 모델의 최종 출력값에 어떻게 기여했는지를 시각적으로 보여준다. 붉은색 영역은 모델 출력을 공격 방향으로 증가시키는 feature를, 파란색 영역은 정상 방향으로 감소시키는 feature를 의미한다.

해당 force plot에서는 TTL 관련 feature가 모델 출력값을 공격 방향으로 크게 이동시키는 주요 요인으로 작용하였다. 이는 특정 flow가 공격으로 판단된 이유를 개별 feature 수준에서 직관적으로 설명해준다.

4-2. OCSVM

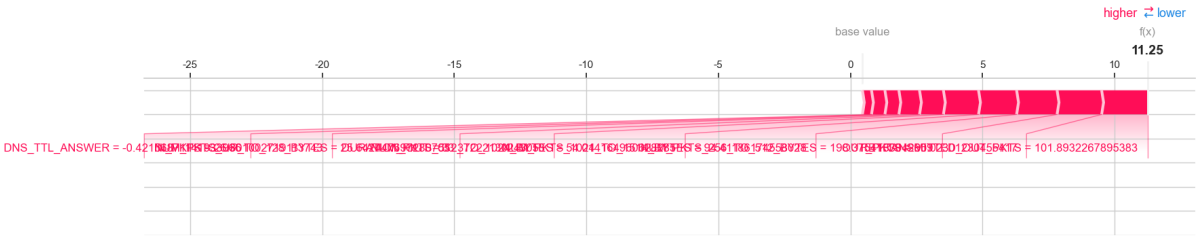

OCSVM의 SHAP force plot은 개별 flow의 anomaly score에 각 feature가 어떻게 기여했는지를 보여준다. 분석 결과, 특정 하나의 feature가 anomaly score를 지배하기보다는, 여러 feature가 소규모로 누적 기여하여 정상 분포로부터의 이탈을 형성하는 구조가 관찰되었다.

5. 결론

TCN은 시계열적 행위 특성과 네트워크 맥락을 기반으로 공격 여부 및 판단 근거를 설명할 수 있는 모델로 적합한 반면, OCSVM은 정상 분포로부터의 이탈 여부를 안정적으로 탐지하는 1차 이상탐지 모델로 적합함을 확인하였다.