Flow 기반 네트워크 공격 탐지를 최신 AI 모델 구현

캡스톤디자인1 - 3차 설계제안서

제출일	2025.10.XX	**소속학부**	소프트웨어학부
과목명	캡스톤디자인프로젝트	**조명**	회의하러왔습니다
담당교수	이상준	**조원**	20203088 김민서 20213126 송우용 20211794 안준엽 20211702 이수아

1. 프로젝트 소개

본 프로젝트는 네트워크 환경에서 발생하는 Flow 로그 데이터를 기반으로 이상행위를 탐지하는 AI 시스템을 개발하는 것을 목표로 한다.

Flow 데이터는 각 패킷이 아닌 세션 단위의 패킷 헤더 필드(메타데이터)를 제공하며, 이를 통해 패킷내용 분석 없이도 효율적이고 가벼운 방식으로 네트워크 이상행위를 감지할 수 있다. 특히 기존의 시그니처 기반 탐지(예: Snort, Suricata)가 미탐이나 오탐 문제를 가지는 반면, 본 프로젝트에서는 AI 모델이 정상 트래픽의 동적 기준선을 학습하여 제로데이 공격이나 비정상적인 트래픽 패턴까지 선제적으로 탐지할 수 있도록 한다.

학습에는 CICIDS2017 등 공공 데이터셋을 활용한다. 이때, 공공 데이터셋은 L3(네트워크) + L4(전송) 헤더 필드 기반의 Flow 데이터셋을 활용하며, 해당 데이터셋을 다양한 머신러닝/딥러닝 모델을 실험하여 이상 데이터셋을 찾아내는 최적의 모델을 만드는 것을 목표로 한다.

2. 기존 시스템 분석

기존의 네트워크 침입탐지 시스템(NIDS)은 대부분 서명(Signature) 기반 탐지 방식을 사용한다. 이러한 시스템은 알려진 공격 패턴에는 효과적이지만, 미리 정의되지 않은 제로 데이 공격이나 변형된 형태의 비정상 트래픽은 탐지하지 못하는 한계를 가진다. 또한 패킷 단위 분석은 처리 비용이 높고, 실시간 대응에 어려움이 있다.

반면 본 프로젝트는 이러한 한계를 극복하기 위해 Flow 로그 기반 분석을 도입한다. Flow 로그는 트래픽을 세션 단위로 집계하여 효율적으로 처리하며 AI의 비지도 학습능력을 결합하여 기존방식으로는 탐지 불가능했던 비정규적/저속 통신 패턴까지 자동화된 예측 및 탐지 서비스를 제공한다.

이러한 접근법은 기존 NIDS인 Snotr나 Suricata가 개별 패킷을 실시간으로 분석하여 규칙과 비교하는 것과 달리, AI모델이 학습한 정상 트래픽의 기준선에서 벗어나는 이상행위를 포착하는데 중점을 둔다. 이를 통해 새로운 유형의 위협에 대한 대응 능력을 강화하고, 탐지 시스템의 효율성과 정확도를 높일 수 있다.

3. 특징 및 구상도

- 특징

패킷 페이로드를 수집하지 않고 Flow 데이터만으로 분석하여 저장 및 연산 비용을 절감할 수 있다. 또한, 2~3가지 머신러닝/딥러닝 모델의 성능을 전처리한 flow 데이터셋으로 학습시킨 후, 가장 성능이 뛰어난 머신러닝/딥러닝 모델을 사용하도록 한다. 이때, 성능은 단순히 정확도만이 아닌 FPR + Recall 트레이드오프(운영에 맞는 임계값) 기준으로 선정한다. 이때 간략한 진행 순서는 다음과 같다. 3개의 딥러닝 모델을 같은 정상 flow 데이터셋으로 정상 트래픽의 복잡한 패턴과 통계적 특성을 학습시킴 → 이때 모델은 학습한 새로 들어온 flow 데이터가 평균에서 벗어나는 이상치를 발견 시 네트워크 공격 탐지 → 학습 시킨 딥러닝 모델 3가지를 평가기준(Accuracy + FPR + Recall 트레이드오프)을 통해 분석 → 평가기준이 제일 좋은 모델 선정 후 진행.

- 진행 순서도

① 네트워크 트래픽 수집 (NetFlow / VPC Flow / Zeek)

↓

② Flow 정규화 및 저장 (Raw Flow DB)

↓

③ 전처리 및 특징 추출

↓

④ AI 모델 학습 (LSTM, TCN-Autoencode 등)

↓

⑤ 성능 평가 및 모델 선정

↓

⑥ 실시간 이상행위 탐지 결과 반환

4. 인터페이스 (UI)

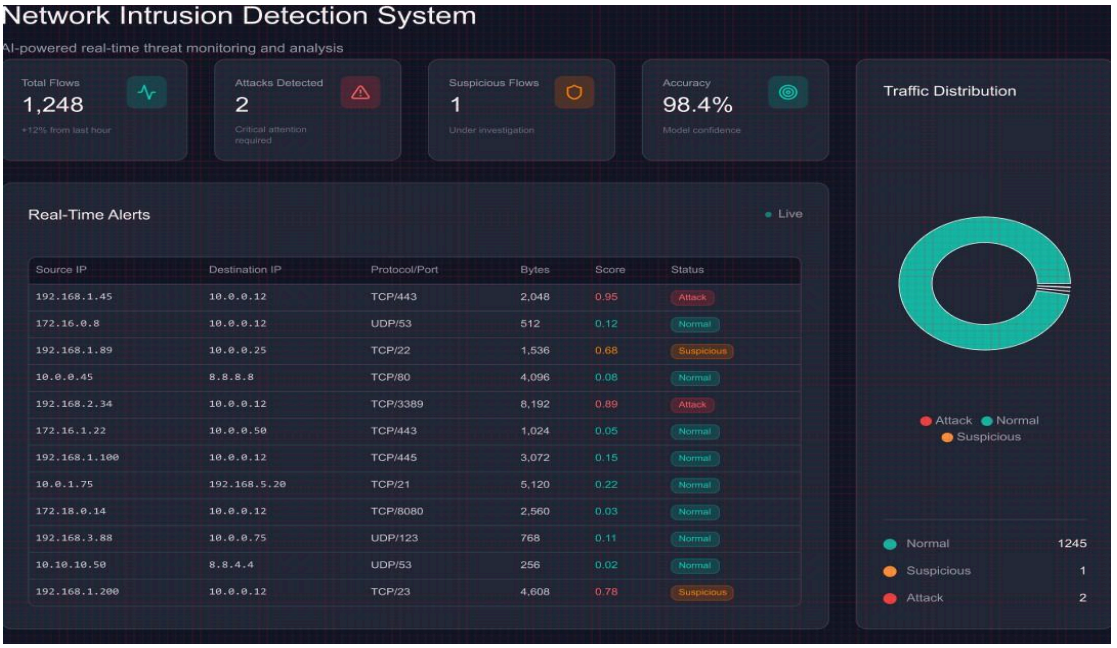

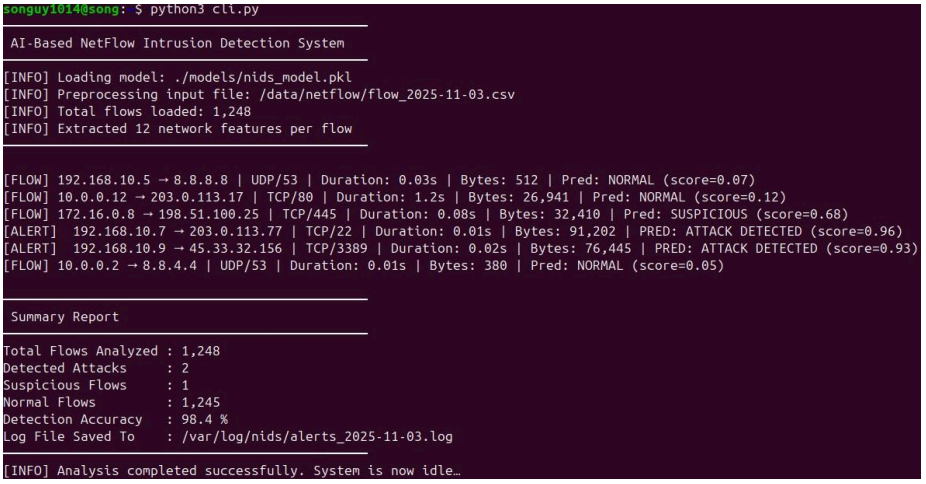

```
songuy1014@song:~$ python3 cli.py
AI-Based NetFlow Intrusion Detection System
[INFO] Loading model: ./models/nids_model.pkl
[INFO] Preprocessing input file: /data/netflow/flow_2025-11-03.csv
[INFO] Total flows loaded: 1,248
[INFO] Extracted 12 network features per flow

[FLOW] 192.168.10.5 → 8.8.8.8 | UDP/53 | Duration: 0.03s | Bytes: 512 | Pred: NORMAL (score=0.07)
[FLOW] 10.0.0.12 → 203.0.113.17 | TCP/80 | Duration: 1.2s | Bytes: 26,941 | Pred: NORMAL (score=0.12)
[FLOW] 172.16.0.8 → 198.51.100.25 | TCP/445 | Duration: 0.08s | Bytes: 32,410 | Pred: SUSPICIOUS (score=0.68)
[ALERT]  192.168.10.7 → 203.0.113.77 | TCP/22 | Duration: 0.01s | Bytes: 91,202 | PRED: ATTACK DETECTED (score=0.96)
[ALERT]  192.168.10.9 → 45.33.32.156 | TCP/3389 | Duration: 0.02s | Bytes: 76,445 | PRED: ATTACK DETECTED (score=0.93)
[FLOW] 10.0.0.2 → 8.8.4.4 | UDP/53 | Duration: 0.01s | Bytes: 380 | Pred: NORMAL (score=0.05)

Summary Report

Total Flows Analyzed : 1,248
Detected Attacks     : 2
Suspicious Flows     : 1
Normal Flows         : 1,245
Detection Accuracy   : 98.4 %
Log File Saved To    : /var/log/nids/alerts_2025-11-03.log

[INFO] Analysis completed successfully. System is now idle…
```

5. 소프트웨어 요구사항(Software Requirement)

본 시스템은 네트워크 플로우(Flow) 데이터를 활용하여 이상 트래픽을 탐지하는 프로그램으로, 다양한 형태의 네트워크 로그 데이터를 입력받아 이를 분석할 수 있도록 설계한다. 수집된 데이터는 전처리 과정을 거쳐 학습용 데이터셋으로 변환되며, 이를 기반으로 최신 AI 모델을 적용하여 정상 트래픽과 비정상 트래픽을 분류한다.

AI 모델은 네트워크 공격 유형에 대한 패턴을 학습하여 새로운 트래픽 데이터가 주어졌을 때 이상 여부를 판단한다. 이를 통해 기존 시그니처 기반 탐지의 한계를 보완하고, 알려지지 않은 공격에도 대응 가능한 이상 탐지 기능을 제공한다.

시스템은 학습 단계와 탐지 단계로 구분되어 있으며, 학습 단계에서는 공개 데이터셋을 기반으로 모델을 학습하고, 탐지 단계에서는 학습된 모델을 이용하여 실시간 또는 저장된 트래픽 데이터를 분석한다. 학습 결과는 탐지 성능 평가를 통해 모델의 정확도를 검증하고, 이를 바탕으로 탐지 기준을 최적화한다.

본 프로젝트는 Flow 기반 네트워크 공격 탐지의 효율성을 향상시키기 위해 최신 인공지능 기술을 적용하고, 다양한 공격 유형에 대한 탐지 성능을 비교·분석함으로써 AI가 탐지한 결과를 유저에게 제공하는 것을 목표로 한다.

6. 시스템 대블록 설계

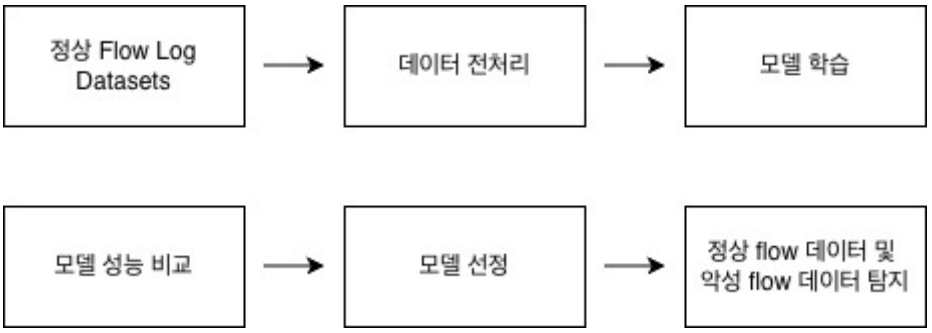

7. 구성도 (Flow Chart)

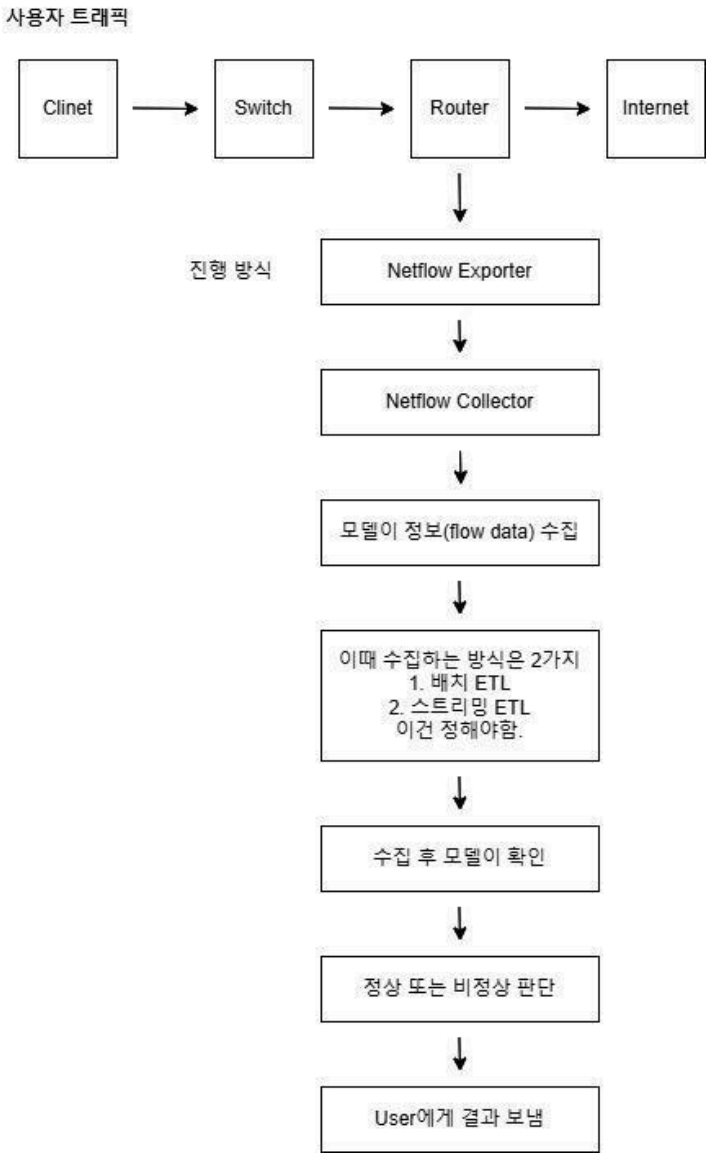

7-1. 상세 _ 시스템 전체 흐름도

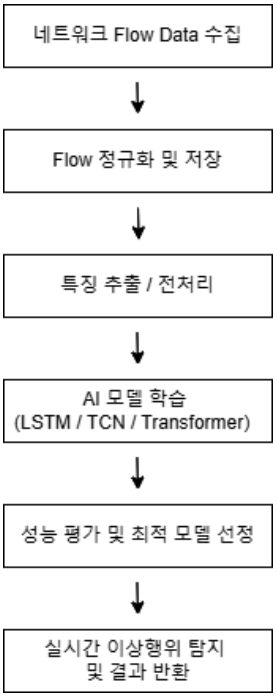

7-2. 상세 _ AI 학습 단계 흐름도

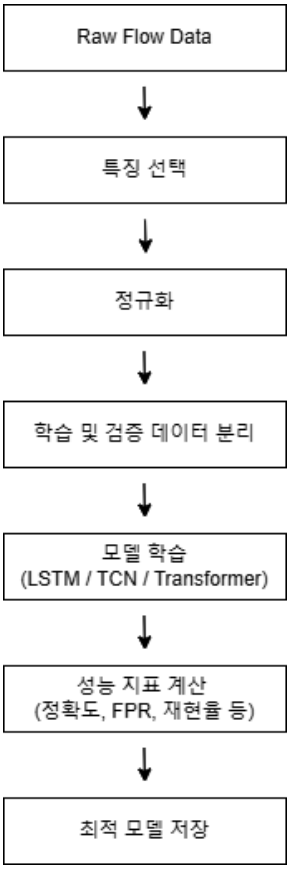

7-3. 상세 _ 실시간 탐지 단계 흐름도

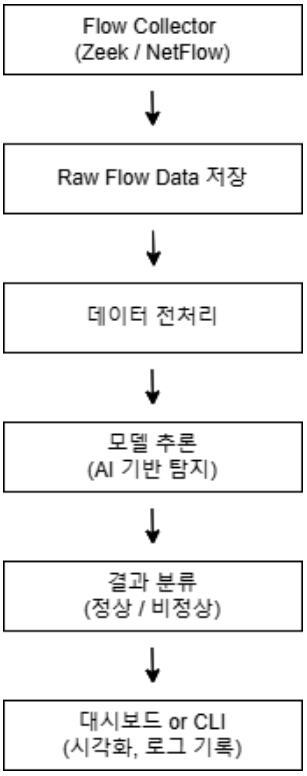

8. 유즈케이스 다이어그램 (Usecase Diagram)

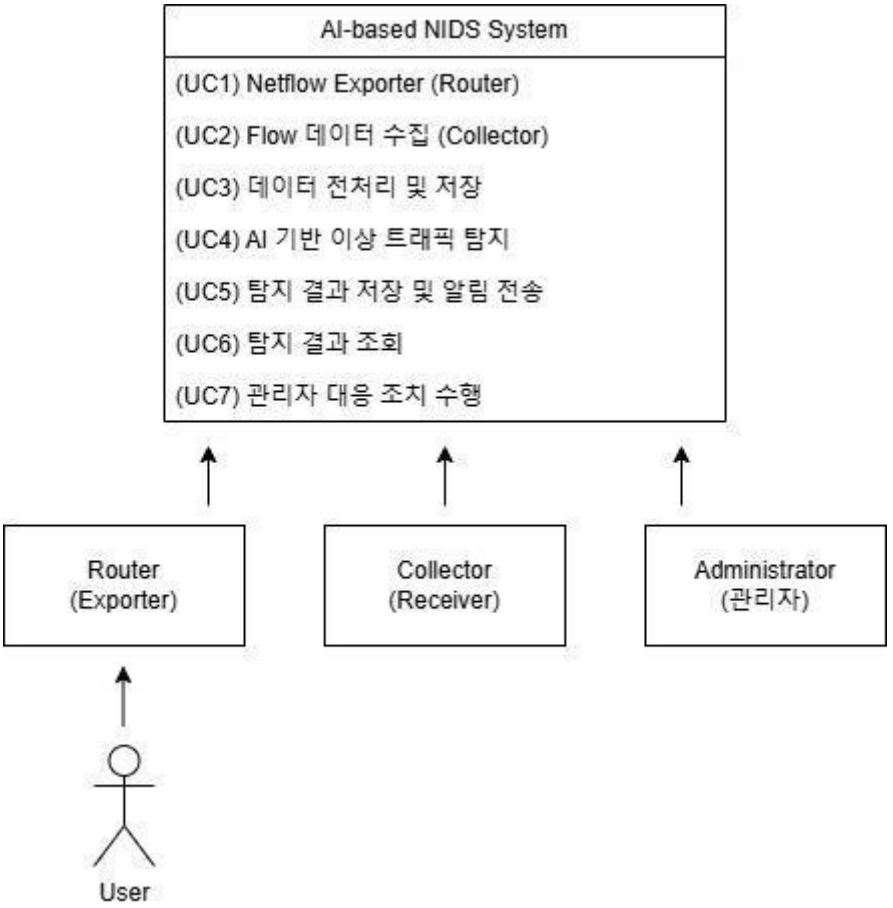
AI-based NIDS System
(UC1) Netflow Exporter (Router)
(UC2) Flow 데이터 수집 (Collector)
(UC3) 데이터 전처리 및 저장
(UC4) AI 기반 이상 트래픽 탐지
(UC5) 탐지 결과 저장 및 알림 전송
(UC6) 탐지 결과 조회
(UC7) 관리자 대응 조치 수행
Router
(Exporter)
Collector
(Receiver)
Administrator
(관리자)
User

9. 클래스 다이어그램 (Class Diagram)

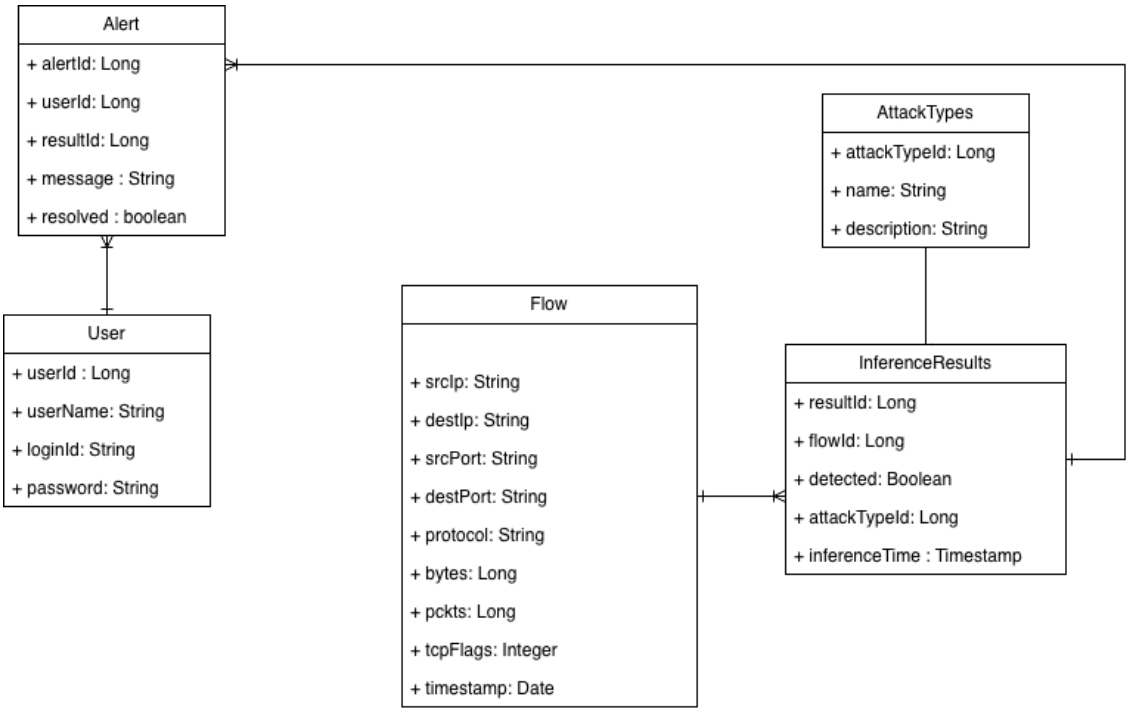

10. 시퀀셜 다이어그램 (Sequential Diagram)

10.1. 실시간 네트워크 트래픽 현상 및 최근 이상 탐지

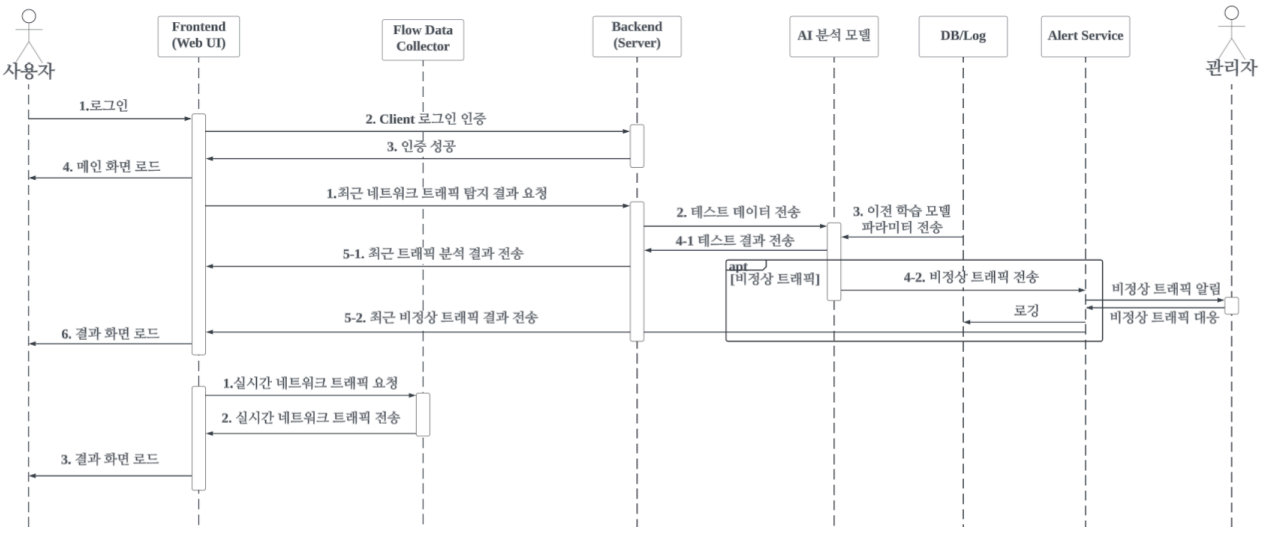

10.2. 사용자 UI 설정

- 자동 로그 기록 여부, 관리자 실시간 알림 여부, 알림 문구, 민감도 조정, 자동화 규칙 설정 등

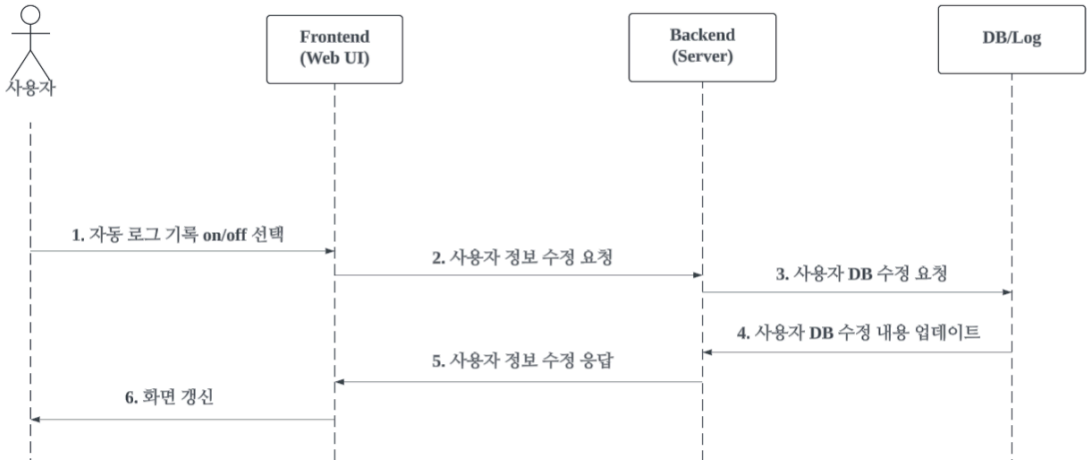

11. 알고리즘 구성 (Algorithm)

11.1. 입력 및 출력 정의

- 입력(Input) : Netflow / Zeek 기반 세션 단위 Flow 로그

  → (src/dst IP, Port, Protocol, Duration, Bytes, Packets, TCP Flags 등)

- 출력(Output) : Flow별

  → 이상 점수

  → 정상 / 비정상 판정 결과

  → 탐지 시간, 공격 유형, 위험도 등 메타정보

11.2 데이터 전처리 및 특징 추출

(1) 정규화(Normalization)

- StandardScaler 또는 RobustScaler 적용
- bytes, duration 등은 log 스케일 변환

(2) 파생 특징 생성

- bytes/sec, pkts/sec, bytes/pkt, 양방향 비율, TCP Flag 비율 등

(3) 결측치 및 이상값 처리

- 결측값은 중앙값 대치, 이상치는 퍼센타일(0.1~99.9%) 범위로 클리핑

(4) 특징 선택(Feature Selection)

- 상관계수, Variance Threshold, Mutual Info 기반 중요 특징만 남김

11.3 모델 구조 (Model Architecture)

본 시스템은 Autoencoder 기반 이상 탐지 모델을 사용한다. Encoder–Decoder 구조로 입력 데이터 X를 재구성하고, 입력값과 복원값 간의 차이($\|X - \hat{X}\|$)를 재구성 오차(Reconstruction Error)로 계산한다. 이 오차가 일정 임계값을 초과하면 비정상으로 판단한다.

(1) 주요 모델 후보

- LSTM-Autoencoder : 시퀀스 종속성을 학습, 저속 C2 및 주기성 트래픽 탐지에 강함
- TCN-Autoencoder : 합성곱 기반 병렬 처리로 빠르고, 장기 의존성 포착력 높음
- Seq-Transformer (경량형) : Attention 기반으로 병렬성 및 효율성 우수

(2) 비교·보조 모델

- Isolation Forest, One-Class SVM과 비교 실험을 수행해 Autoencoder 성능 검증
- 필요 시 앙상블 구성으로 FP(오탐) 감소

11.4 학습 및 검증 (Training & Validation)

(1) 데이터 분할 : Train / Validation / Test (시간 순서 유지)

(2) 학습 방식 : 정상 데이터만으로 비지도 학습 (MSE, MAE 기반 Reconstruction Loss)

(3) 평가 지표 : Accuracy, Recall, FPR, PR-AUC, ROC-AUC

(4) 모델 선정 기준 : 성능(FPR+Recall) + 추론속도 + 메모리 효율

(5) 최종 모델 : LSTM-AE 구조를 기반으로 선정

11.5 임계값(Threshold) 설정 및 탐지 로직

- 정상 검증 데이터의 재구성 오차 분포로부터

  → $\tau = \mu + k \cdot \sigma$ 또는 상위 99.5% 퍼센타일 기준으로 임계값 설정

- 실시간 Flow 입력 시 $\|X - \hat{X}\| \geq \tau$ → 비정상으로 판정

11.6 실시간 탐지 절차 (Real-time Inference Process)

(1) Flow Collector(Zeek/NetFlow)에서 Flow 로그 수집

(2) Raw Flow 저장 → 전처리

(3) 학습된 Autoencoder 모델 추론

(4) 재구성 오차 계산 → 임계값 비교

(5) 결과(정상/비정상) → Dashboard·CLI에 시각화 및 로그 저장

→ "실시간 탐지 단계 흐름도 Flow Chart" 참고

11.7 알고리즘 작동 예시 (Model Workflow)

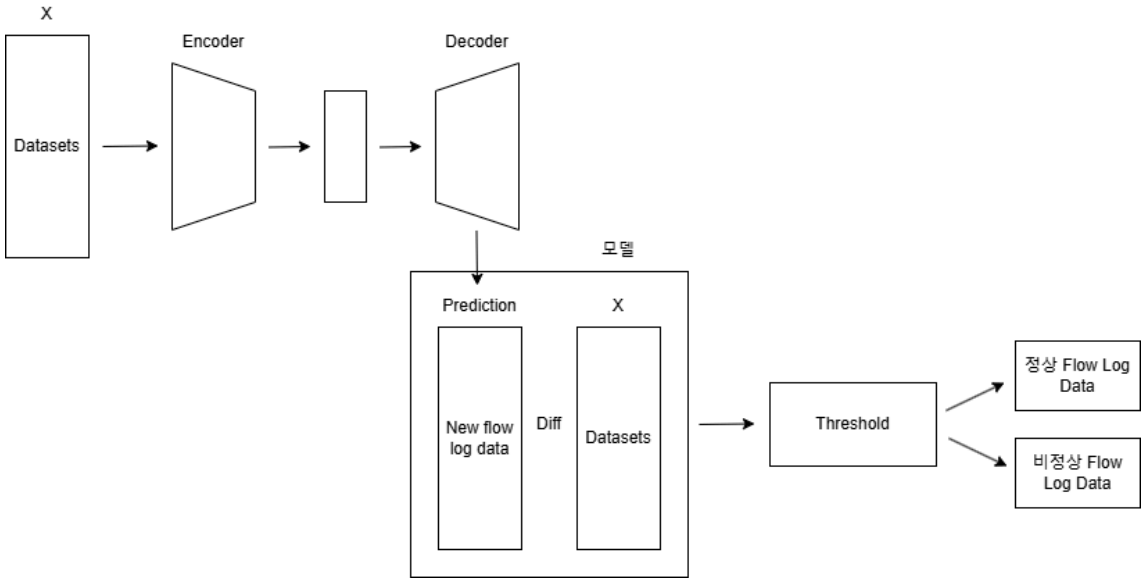

(그림 11-1) Autoencoder 기반 Flow 이상 탐지 모델 구조도

입력: Datasets (Flow Log)

↓

Encoder → 잠재벡터 z 생성

↓

Decoder → 입력 재구성 ($\hat{x}$)

↓

오차 계산 $|x - \hat{x}|$

↓

Threshold 비교 → 정상 / 비정상 판정

12. 데이터베이스 테이블 구조 (DB Table)

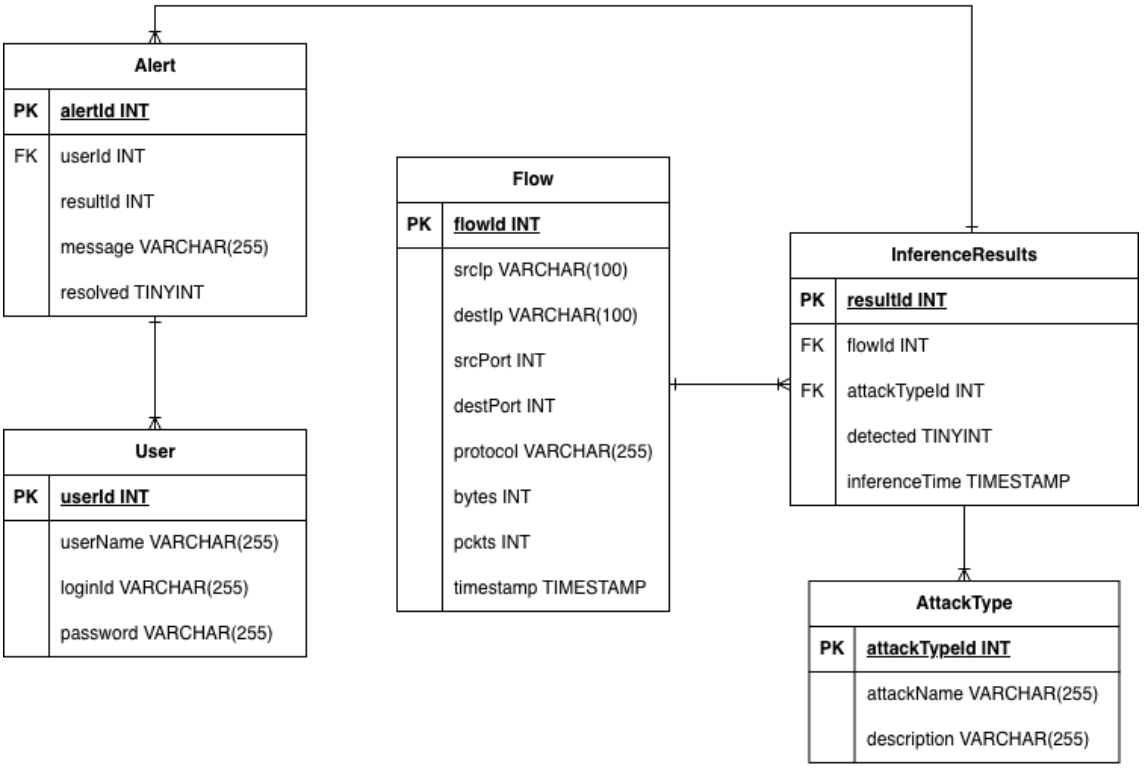

13. 시나리오 (Senario)

1. 사용자는 회사 내부망에서 제공된 웹사이트 주소로 접속하여 로그인한다.

2. 로그인 후, 메인 화면에서 실시간 네트워크 트래픽 현황과 최근 이상 탐지 결과를 직관적으로 확인할 수 있다.

3. 사용자는 메뉴에서 탐지 설정을 선택해 “이상행위 탐지 시 관리자에게 실시간 알림”, “자동 로그 기록” 등의 옵션을 직접 활성화해둔다.

4. [조건: 실시간 탐지 결과] 업무 시간 중 트래픽 패턴에 변화(특정 IP로부터 비정상적인 대량 접속 등)가 발생하면, AI 탐지 모델이 이를 자동으로 분석해 “비정상 트래픽 탐지” 배너와 팝업 알림을 띄운다.

5. 사용자는 팝업을 통해 상세 분석 리포트(공격 IP, 공격 유형, 탐지 시간 등)를 즉시 확인한다.

6. 관리자는 웹사이트 내 제공된 빠른 조치(예: 해당 IP 차단/모니터링) 버튼을 클릭하여 실시간으로 대응한다.

7. 복수의 알림이 동시 발생하거나 우선순위가 겹치는 이벤트가 있으면, 웹사이트는 중요도 기준 자동정렬, 가장 위험도가 높은 알림부터 상단에 배치하여 신속 대응을 가능하게 한다.

8. 모든 탐지 내역과 대응 기록은 웹사이트 내 로그 관리 메뉴에 자동 저장된다. 관리자는 여기서 전체 이력 및 분석 리포트를 다운로드해 내부 공유 혹은 추가 조사에 활용할 수 있다.

9. 사용자는 자신의 필요에 따라 알림 문구/민감도/자동화 규칙을 직접 설정하고, UI에서 각 기능을 편리하게 수정하면서 시스템을 운용한다.

14. 간략수행계획서

순차적으로 프로젝트 중 다음의 핵심 기능들을 구현하도록 한다.

① Flow 데이터 수집 및 전처리

② AI 모델 학습 및 성능 평가

③ 지표가 가장 좋은 모델 선정

④ 배포

15. 관련기술

- Flow 데이터 분석 기술

아래의 데이터셋을 전체 공통 전처리를 진행한다.

- 머신러닝/딥러닝 알고리즘

1. LSTM-Autoencoder

이유: 시퀀스 재구성오차로 이상을 잡음(저속 C2·주기성에 강함). 논문 결과와도 부합.

2. TCN-Autoencoder (Temporal Convolutional Network)

이유: 병렬 처리로 학습/추론 빠름. 장기 의존성 포착 능력 좋음. 경량화 시 LSTM보다 효율적일 때가 많음.

3. Seq-Transformer (경량화 버전) 또는 LSTM + Attention (작은 Transformer 블록)

이유: 병렬 처리로 빠르며, 장기 의존성 포착 능력 우수. 경량화에 유리.

→ Seq-AE(1D-CNN Encoder + LSTM Decoder)

→ 딥러닝 3종 대신 한 모델(예: LSTM-AE) + 비딥(예: IsolationForest) 을 포함해 앙상블 성능을 보는 것도 현실적(논문은 I-Forest/AE/SVM 비교 결과 제시).

담당		기간	10월				11월				12월				1월				2월				3월				4월			
			1학기												(방학포함) 2학기															
		분	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
설계	모두	아이디																												

		어제안																													
	모듈	기술분석및자료습득																													
	모듈	Usecase Diagram및Flow																													

		chart작성																													
	모두	최종제안서보완및정리																													
공통	강민규	알림정보받아오기																													
	배성원	매크로생성시																													

		관련파일생성																												
	신중권	매크로생성시동작이벤트받아오기																												
	강민규	매크로생성시동작이벤																												

		트명령어화																													
	신중권	매크로생성시동영상촬영																													
	신중권	알림내용분석클래스작성																													

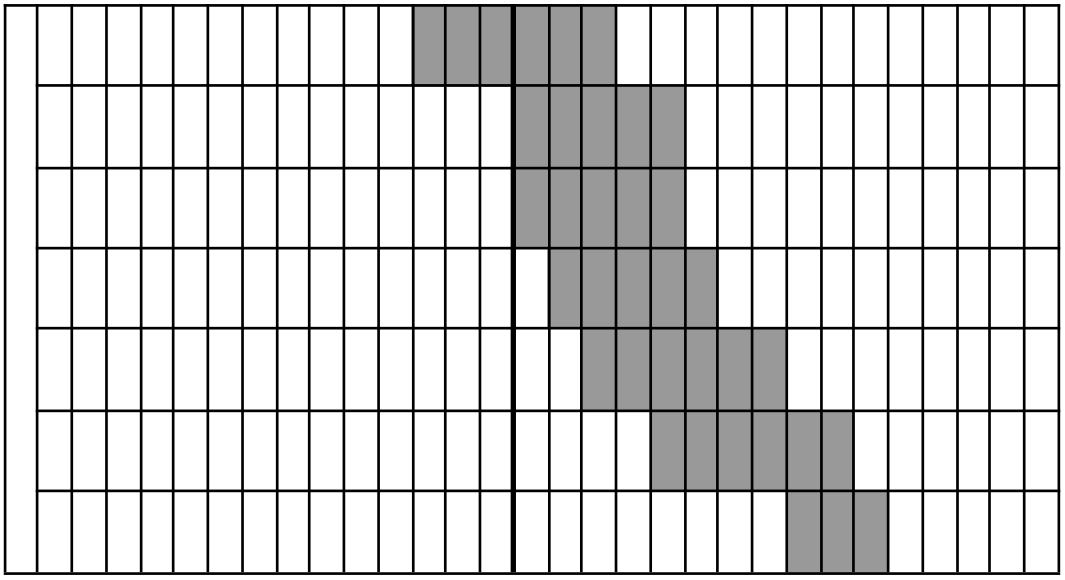

- 데이터셋

1. https://staff.itee.uq.edu.au/marius/NIDS_datasets _ NetFlow Datasets for ML-based NIDS (NF-UNSW-NB15, NF-BoT-IoT 등)

2. https://zenodo.org/records/6610489 _ AIT Netflow Dataset

3. https://repo.researchdata.hu/dataset.xhtml?persistentId=hdl%3A21.15109%2FARP%2FFBIIOZ _ Anonymized Netflow / security scan data (Hungary ARP repository)

4. https://www.mdpi.com/2306-5729/8/1/18 _ UWF-ZeekData22 / UWF-ZeekDataFall22

5. https://www.kaggle.com/datasets/mimansari/dns-and-connections-log-zeek-or-corelight _ Kaggle: DNS + Connections log (Zeek/Corelight)

6. https://www.unb.ca/cic/datasets/ids-2017.html _ CIC-IDS2017

7. https://research.unsw.edu.au/projects/unsw-nb15-dataset _ UNSW-NB15

8. https://www.caida.org/catalog/datasets/about/downloads/ _ CAIDA 데이터셋

9. https://registry.opendata.aws/cse-cic-ids2018/ _ CSE-CIC-IDS2018

(a.k.a. CIC-IDS2018)

16. 기대효과

- 실시간 이상행위 탐지: 새로운 공격 유형에도 대응 가능한 AI 기반 탐지 시스템 구축
- 운영 효율성 향상: 패킷 기반 분석 대비 계산 비용 절감 및 빠른 처리
- 확장성 확보: 클라우드 환경, IoT 네트워크, 기업망 등 다양한 환경에 적용 가능
- 교육 및 연구 활용: Flow 기반 AI 탐지 연구 및 실무 실습 데이터로 활용 가능

활용 예)

- 사용자는 우리 모델 다운 → 모델이 사용자의 컴퓨터에 있으면, 이 모델이 네트워크 flow 데이터 소스를 분석해서 학습해둔 데이터에서 벗어나는 이상치가 존재할 시, 네트워크 공격 감지 → 사용자에게 네트워크 공격 탐지 되었다고 출력

17. 참고문헌

-https://manuscriptlink-society-file.s3-ap-northeast-1.amazonaws.com/kics/conference/koreaai2021/presentation/0046.pdf _ 네트워크 플로우 데이터 기반 이상징후 탐지 인공지능 모델 성능 비교

- https://www.earticle.net/Article/A403316 _ 머신러닝과 딥러닝을 활용한 악성 패킷 탐지 기술 연구